




DEPARTAMENTO  
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

# Aprendizaje Automático

2025-2c

**Clase 1:**  
Administrativos  
Introducción a Aprendizaje Automático  
Aprendizaje Supervisado



# Hoy

- Cuestiones administrativas: horarios, docentes, web, etc.
- Objetivos, correlatividades, evaluación, bibliografía.
- Presentación del contenido de toda la materia.
- Primera clase teórica (aprendizaje supervisado).

# Aprendizaje Automático - 3er bimestre 2025

**Horario y lugar:** 09:00 a 13:00. **Aula 1303** (Pabellón 0+inf)

**Campus virtual:** <https://campus.exactas.uba.ar/course/view.php?id=669>

**Importante:** Tienen que estar **matriculados** en la materia. La comunicación será a través del **campus virtual**.

- **2 puntos** de optativa para **Licenciatura en Computación (plan 93)**.
- **64 créditos** para **Licenciatura en Computación (plan 2023)**.
- **64 horas** para **Licenciatura en Ciencia de Datos**.
- **2 puntos** para **Licenciatura en Física (combo 2 + 3 si hacen las dos)**.
- **3 puntos** para **el Doctorado en Computación (combo 3 + 2 si hacen las dos)**.



Noé Hsueh (Ay2)



Cecilia Bolaños (Ay1)



Leandro Lombardi (Prof)



Pablo Brusco (Prof)

# Dinámica de la materia

- **Clases teóricas.** Subiremos las diapos instantes antes de la clase.
- **Guías prácticas:** Cada tema tendrá asociada una guía práctica que subiremos al campus al finalizar la teórica del tema.
- **Clases prácticas:** Durante cada clase práctica trabajaremos con los ejercicios de las guías. Se recomienda fuertemente ir al día con las guías.
- **Parciales:** Los armaremos suponiendo que hicieron las guías.
- **Notebooks:** Serán publicados junto con los cuestionarios asociados.
- **Lecturas obligatorias semanales:** Aprox 1 cap. de un libro por semana.
- **Cuestionarios obligatorios:** Semanalmente habrá cuestionarios en formato de google forms sobre la clase, los notebooks y las lecturas obligatorias. Por defecto, tendrán poco más de 1 semana para resolverlos. Ej, si se presentan el Martes luego de la clase, tendrán tiempo hasta el miércoles de la siguiente a noche.

## Régimen de Aprobación (vale para las dos bimestrales)

- Para aprobar la cursada deben aprobar el **parcial**, el **TP**, leer la **bibliografía obligatoria** que se presenta al final de cada clase y **completar los cuestionarios semanales obligatorios**.
- Se puede **promocionar** obteniendo nota 7 o superior, aprobando el TP, participando de la competencia del TP y habiendo aprobado 5 de los 6 cuestionarios.
- Para quienes **recuperen** un parcial (habiéndolo aprobado o no), la nota que cuenta es la del recuperatorio.
- Quienes obtengan nota inferior a 7 el parcial deben dar el **final**.

# Fechas AA1

## TP-AA1:

- Presentación Jueves **04/09**
- Primera Entrega: Jueves **18/09** – 9am
- Entrega final: Jueves **02/10** – 9am
- Peer Review: Martes **07/10** – 9am

## Parcial-AA1:

- Fecha: Jueves **09/10**
- Recu 1: Martes **09/12** (atención: es a fin del cuatrimestre)

En caso de ir a recu no hay problema con que cursen AA2.

# Fechas (tentativas) AA2

## TP-AA2:

- Presentación Martes **28/10**
- Envío slides (entrega): Lunes **01/12**– Hasta 23:59 pm.
- Presentación alumnos: Martes **02/12**

## Parcial-AA2:

- Fecha: Jueves **20/11**
- Recu: Jueves **11/12**

**Recordatorio: inscripciones (15-09 al 21-09)**

**– Vale también para AAG**

# Aprendizaje Automático I


Optativa del Departamento de Computación.

## Objetivos de la materia:

Una **introducción abarcativa** de los principales **conceptos, decisiones algorítmicas** y **efectos** de distintos **métodos** de aprendizaje automático.

## Correlativas:

- Compu: AED 3 + MetNum + Proba
- Datos: AED 3 + ALC + Proba
- Física: Labo 5 (TPs), Teo 3, Cálculo N.



## Bibliografía (AA1):


- James, Witten, Hastie & Tibshirani, **An Introduction to Statistical Learning with Applications in Python**, Springer, 2023. PDF y recursos: <https://www.statlearning.com/>
- Mitchell, **Machine Learning**, McGraw-Hill, 1997. [PDF escaneado](#) | [PDF original](#)
- Müller & Guido, **Introduction to Machine Learning with Python**, O'Reilly, 2016. [PDF](#)
- Hastie, Tibshirani & Friedman, **The Elements of Statistical Learning**, 2nd ed, Springer, 2009. [PDF](#)



# Herramientas



[Home](#) [Installation](#) [Documentation](#) [Examples](#)



# scikit-learn

Machine Learning in Python

- Simple and efficient tools for data mining and data analysis
- Accessible to everybody, and reusable in various contexts
- Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable - BSD license

## Classification

Identifying to which category an object belongs to.

**Applications:** Spam detection, Image recognition.

**Algorithms:** SVM, nearest neighbors, random forest, ... [— Examples](#)

## Regression

Predicting a continuous-valued attribute associated with an object.

**Applications:** Drug response, Stock prices.

**Algorithms:** SVR, ridge regression, Lasso, ... [— Examples](#)

## Clustering

Automatic grouping of similar objects into sets.

**Applications:** Customer segmentation, Grouping experiment outcomes

**Algorithms:** k-Means, spectral clustering, mean-shift, ... [— Examples](#)

## Dimensionality reduction

Reducing the number of random variables to consider.

**Applications:** Visualization, Increased efficiency

**Algorithms:** PCA, feature selection, non-negative matrix factorization. [— Examples](#)

## Model selection

Comparing, validating and choosing parameters and models.

**Goal:** Improved accuracy via parameter tuning

**Modules:** grid search, cross validation, metrics. [— Examples](#)

## Preprocessing

Feature extraction and normalization.

**Application:** Transforming input data such as text for use with machine learning algorithms.

**Modules:** preprocessing, feature extraction. [— Examples](#)

# Programa (AA 1)

- Aprendizaje de **conceptos**
- **Evaluación** y **selección** de modelos
- **Sesgo** y **Varianza**
- **Clasificadores Generativos y Discriminativos**: Árboles, KNN, Naive Bayes, LDA, SVM, logística.
- **Ensamblados**: Bagging, Random Forest, Boosting
- **Clustering**: K-Means, GMM, algoritmo EM, clustering jerárquico aglomerativo, DBSCAN
- **Métricas** y evaluación de clasificadores probabilísticos
- **Ingeniería de atributos**
- **Sistemas de Recomendación**

# Introducción

# ¿Qué debería saber después de esta clase?

- Def Problemas de aprendizaje bien planteados
- Aprendizaje supervisado:
  - Modelos / Hipótesis
  - Espacio de Atributos
  - Espacio de Hipótesis
  - Espacio de Instancias
  - Fronteras de decisión
  - Clasificación vs Regresión
  - Navaja de Ockham.
  - Sustento del Aprendizaje Inductivo.
  - Aprendizaje automático como un problema de búsqueda.
  - Generalización: Sobreajuste, subajuste.
  - Sesgo inductivo

# Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada un texto que describe un objeto mi living, ¿es una silla?

# Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?

# Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



# Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?





# Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



# Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



# Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



# ¿Qué pasó?

¿Qué materia me perdí?

# ¿Qué pasó?

¿Qué materia me perdí?

Hay problemas con **reglas** tan **complejas** que no podemos atacarlos con programación clásica...

# Parte 1

Nociones básicas de  
**Aprendizaje Automático**

# Aprendizaje Automático (Machine Learning)

Aprender a partir de **ejemplos y experiencia** ...

... reglas complejas...

# Aprendizaje Automático (Machine Learning)


Aprender a partir de **ejemplos y experiencia** ...

... reglas complejas...


... ¿pero cómo?



Queríamos un programa que ...




"Silla"




No "Silla"


Queríamos un programa que ...



Queríamos un programa que ...



Queríamos un programa que ...



# Queríamos un programa que ...




# Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso




# Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores de manera **automática**. Tres pasos fundamentales.

## Primer paso



## Segundo paso



## Tercer paso




# Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso






# Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso



# Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso



# Aprendizaje supervisado

## Recolección de datos



Instancias  
(ejemplos)



Atributos  
(features)

Etiqueta

| Atributos<br>(features) |        |        | Etiqueta   |
|-------------------------|--------|--------|------------|
| PESO                    | COLOR  | #PATAS | ¿Es Silla? |
| 3.4                     | Marrón | 3      | Sí         |
| 10.2                    | Varios | 2      | No         |
| 4.5                     | Verde  | 4      | No         |
| 5.2                     | ???    | 4      | Sí         |
| 3.2                     | Marrón | 3      | No         |
| ...                     | ...    | ...    | ...        |

# Aprendizaje supervisado

## Recolección de datos



Instancias  
(ejemplos)



Atributos  
(features)

Etiqueta

| PESO | COLOR  | #PATAS | ¿Es Silla? |
|------|--------|--------|------------|
| 3.4  | Marrón | 3      | Sí         |
| 10.2 | Varios | 2      | No         |
| 4.5  | Verde  | 4      | No         |
| 5.2  | ???    | 4      | Sí         |
| 3.2  | Marrón | 3      | No         |
| ...  | ...    | ...    | ...        |

# Aprendizaje supervisado

## Recolección de datos



Instancias  
(samples)


| 1 → 2 → 3               |        |        |                      |
|-------------------------|--------|--------|----------------------|
| Atributos<br>(features) |        |        | Etiqueta<br>(labels) |
| PESO                    | COLOR  | #PATAS | ¿Es Silla?           |
| 3.4                     | Marrón | 3      | Sí                   |
| 10.2                    | Varios | 2      | No                   |
| 4.5                     | Verde  | 4      | No                   |
| 5.2                     | ???    | 4      | Sí                   |
| 3.2                     | Marrón | 3      | No                   |
| ...                     | ...    | ...    | ...                  |

# Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso



# Aprendizaje supervisado

Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



| PESO | COLOR  | #PATAS | Siila? |
|------|--------|--------|--------|
| 3.4  | Marrón | 3      | Si     |
| 10.2 | Varios | 2      | No     |
| 4.5  | Verde  | 4      | No     |
| 5.2  | ???    | 4      | Si     |
| 3.2  | Marrón | 3      | No     |
| ...  | ...    | ...    | ...    |



Lleno de reglas



# Aprendizaje supervisado

## Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



| PESO | COLOR  | #PATAS | Siila? |
|------|--------|--------|--------|
| 3.4  | Marrón | 3      | Si     |
| 10.2 | Varios | 2      | No     |
| 4.5  | Verde  | 4      | No     |
| 5.2  | ???    | 4      | Si     |
| 3.2  | Marrón | 3      | No     |
| ...  | ...    | ...    | ...    |



Lleno de reglas





# Aprendizaje supervisado

## Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



| PESO | COLOR  | #PATAS | Siila? |
|------|--------|--------|--------|
| 3.4  | Marrón | 3      | Sí     |
| 10.2 | Varios | 2      | No     |
| 4.5  | Verde  | 4      | No     |
| 5.2  | ???    | 4      | Sí     |
| 3.2  | Marrón | 3      | No     |
| ...  | ...    | ...    | ...    |



Lleno de reglas



# Aprendizaje supervisado

## Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



| PESO | COLOR  | #PATAS | Siila? |
|------|--------|--------|--------|
| 3.4  | Marrón | 3      | Sí     |
| 10.2 | Varios | 2      | No     |
| 4.5  | Verde  | 4      | No     |
| 5.2  | ???    | 4      | Sí     |
| 3.2  | Marrón | 3      | No     |
| ...  | ...    | ...    | ...    |



Lleno de reglas



```
def es_silla(x):  
    return False
```

Caja vacía



```
def es_silla(x):  
    if (x.patas < 2 && x.peso < 0.3):  
        return True  
  
    if (x.patas > 3 && x.peso < 4.3):  
        if (x.peso > 2.3 && x.patas == 4):  
            return True  
        else:  
            return False  
  
    if (x.peso > 1000):  
        return False  
    else:  
        if x.color != 3:  
            return False  
        else:  
            if x.peso > 500:  
                ...  
    ...
```

Caja vacía + Datos = Caja con reglas



```

def es_silla(x):
    if (x.patas < 2 && x.peso < 0.3):
        return True

    if (x.patas > 3 && x.peso < 4.3):
        if (x.peso > 2.3 && x.patas == 4):
            return True
        else:
            return False


    if (x.peso > 1000):
        return False
    else:
        if x.color != 3:
            return False
        else:
            if x.peso > 500:
                ...
            ...

```

Caja vacía + Datos = Caja con reglas

## Reglas que NO programaremos

Habrà algún algoritmo que las genere por nosotros




# Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores de manera **automática**. Tres pasos fundamentales.


Primer paso



Segundo paso



Tercer paso




# Aprendizaje supervisado

## Hacer predicciones



Instancia nunca antes vista

| DESCRIPCIÓN |        |
|-------------|--------|
| PESO        | 6.2 KG |
| COLOR       | Negro  |
| #PATAS      | 4      |




# Aprendizaje supervisado

## Hacer predicciones



Instancia nunca antes vista

| DESCRIPCIÓN |        |
|-------------|--------|
| PESO        | 6.2 KG |
| COLOR       | Negro  |
| #PATAS      | 4      |






# Aprendizaje supervisado

## Hacer predicciones

Instancia nunca antes vista

| DESCRIPCIÓN |        |
|-------------|--------|
| PESO        | 6.2 KG |
| COLOR       | Negro  |
| #PATAS      | 4      |



En muchos casos  
produciendo un  
puntaje (o score)  
asociado.

97%



# Parte 2



¿Qué es lo que pasa realmente?

Concepto clave hoy y en el resto de la materia.


# ¿Cómo se piensan los “atributos”?

Atributos (features en inglés)

|          |        |
|----------|--------|
| PESO     | 4.2 KG |
| #PATAS   | 3      |
| MATERIAL | Madera |
| Silla    |        |

|          |        |
|----------|--------|
| PESO     | 2 KG   |
| #PATAS   | 0      |
| MATERIAL | Vidrio |
| Maceta   |        |

(Peso, #Patatas, Material)



|          |      |
|----------|------|
| PESO     | 9 KG |
| #PATAS   | 4    |
| MATERIAL | ??   |
| Mesa     |      |

|          |        |
|----------|--------|
| PESO     | 10 KG  |
| #PATAS   | 3      |
| MATERIAL | Vidrio |
| Mesa     |        |

# ¿Cómo se piensan los “atributos”?

Atributos (features en inglés)

|          |     |
|----------|-----|
| PESO     | 4.2 |
| #PATAS   | 3   |
| MATERIAL | 1   |
| Silla    |     |

|          |   |
|----------|---|
| PESO     | 2 |
| #PATAS   | 0 |
| MATERIAL | 2 |
| Maceta   |   |

(Peso, #Patas, Material)




|          |   |
|----------|---|
| PESO     | 9 |
| #PATAS   | 4 |
| MATERIAL | 0 |
| Mesa     |   |

|          |    |
|----------|----|
| PESO     | 10 |
| #PATAS   | 3  |
| MATERIAL | 2  |
| Mesa     |    |


# ¿Cómo se piensan los “atributos”?

Atributos (features en inglés)




# ¿Qué pinta tiene un clasificador?

**Modelo 1** (construido con Algoritmo  $L_1$ )



Espacio de Atributos ( $\mathbb{R}^3$ )

**Modelo 2** (construido con Algoritmo  $L_2$ )




Espacio de Atributos ( $\mathbb{R}^3$ )

# ¿Qué pinta tiene un clasificador?

**Modelo 1** (construido con Algoritmo  $L_1$ )

¿Cómo lo programo?




Atributos en  $\mathbb{R}^3$

**No** se programan,

- Se decide la forma.
- Se programa la infraestructura.
- Se entrena, valida y evalúa.

# ¿Qué pinta tiene un clasificador?

**Modelo** (Ejemplo - Atributos en  $\mathbb{R}^2$ )




**Ejemplo:** Algoritmo que iterativamente va generando estas “**fronteras de decisión**” (regiones del espacio de atributos asignados a una clase o la otra, en este caso 2 regiones, la roja y la azul)



# ¿Qué pinta tiene un clasificador?

**Modelo** (Ejemplo - Atributos en  $\mathbb{R}^2$ )



**Ejemplo:** Algoritmo que iterativamente va generando estas “**fronteras de decisión**” (regiones del espacio de atributos asignados a una clase o la otra, en este caso 2 regiones, la roja y la azul)


**¿Predecir?** Una vez que algoritmo convergió (las fronteras de decisión quedan definidas)

Podemos asignar una clase a una instancia nueva, en este caso  será clasificada como clase azul.

# Garbage in - Garbage out


¡Una mala elección de atributos puede hacer el problema mucho más complejo!  
**¿Por qué?**

(Peso, Color, #Ruedas)




Espacio de Atributos  
(atributos en  $\mathbb{R}^3$ )

(Peso, #Patas, Material)



Espacio de Atributos  
(atributos en  $\mathbb{R}^3$ )

(Material, #Ojos, #Ruedas)



Espacio de Atributos  
(atributos en  $\mathbb{R}^3$ )

# Aprendizaje supervisado

## Puntos a tener en cuenta

### RECOLECCIÓN DE DATOS

¿Hay suficientes datos?

¿Los datos están balanceados?

¿Sobre cuántos entreno mis modelos?

¿Sobre cuántos valido mis modelos?

¿Qué distribución siguen los datos?

...

### MODELO

¿Elegí el algoritmo adecuado?

¿Con qué hiperparámetros tiene sentido probar?

¿Cómo puedo testearlo?

¿Puedo reutilizar un clasificador ya entrenado?

....

### PREDICCIÓN

¿Cómo mido mis resultados?

¿Son resultados que generalizan al problema en el mundo exterior?

¿Qué métricas conviene utilizar?

¿Puedo medir significancia estadística?

¿Es comparable mi resultado con otros resultados similares?

....

# Aprendizaje supervisado

## Puntos a tener en cuenta

### RECOLECCIÓN DE DATOS

¿Hay suficientes datos?

¿Los datos están balanceados?

¿Sobre cuántos entreno mis modelos?

¿Sobre cuántos valido mis modelos?

¿Qué distribución siguen los datos?

...

### MODELO

¿Elegí el algoritmo adecuado?

¿Con qué hiper parámetros tiene sentido probar?

¿Cómo puedo testearlo?

¿Puedo reutilizar un clasificador ya entrenado?

....

### PREDICCIÓN

¿Cómo mido mis resultados?

¿Son resultados que generalizan al problema en el mundo exterior?

¿Qué métricas conviene utilizar?

¿Puedo medir significancia estadística?

¿Es comparable mi resultado con otros resultados similares?

....

# Aprendizaje supervisado

## Puntos a tener en cuenta

### RECOLECCIÓN DE DATOS

¿Hay suficientes datos?

¿Los datos están balanceados?

¿Sobre cuántos entreno mis modelos?

¿Sobre cuántos valido mis modelos?

¿Qué distribución siguen los datos?

...

### MODELO

¿Elegí el algoritmo adecuado?

¿Con qué hiper parámetros tiene sentido probar?

¿Cómo puedo testearlo?

¿Puedo reutilizar un clasificador ya entrenado?

....

### PREDICCIÓN (Inferencia)

¿Cómo mido mis resultados?

¿Son resultados que generalizan al problema en el mundo exterior?

¿Qué métricas conviene utilizar?

¿Puedo medir la significancia estadística?

¿Es comparable mi resultado con otros resultados similares?

....

## Inteligencia Artificial (IA) (Artificial Intelligence)

Cualquier técnica que permita a las computadoras resolver tareas que involucran **“imitar inteligencia humana”**.

- Chatbots que pueden conversar con usuarios.
- Sistemas que juegan al ajedrez u otros juegos.
- Asistentes personales como Siri o Alexa.
- Sistemas expertos.
- Lógica difusa.
- Algoritmos Genéticos.
- Programación Lógica.
- Simulador de tráfico.
- etc.

## Aprendizaje Automático (AA) (Machine Learning)

Permitir que las máquinas **aprendan de los datos y/o mejoren su rendimiento con el tiempo** sin ser explícitamente programadas

- Identificador de Spam.
- Predicción de precios de propiedades.
- Detección de Fraude.
- Agrupamiento de clientes.
- Detección de tópicos en texto.
- Mapeo automático.
- AlphaGo.
- etc.

## Aprendizaje Profundo (AP) (Deep Learning)

Utiliza **redes neuronales** para modelar y comprender patrones complejos en grandes cantidades de datos.

- Reconocimiento de imágenes.
- Reconocimiento de voz.
- Traducción automática.
- Modelos generativos.
- etc.

# Definición: “Problemas de aprendizaje bien planteados”

[Mitchell Sec. 1.1]

Un programa se dice que aprende a partir de la **experiencia E** con respecto a una **tarea T** y una medida de **performance P**, si su performance en la **tarea T**, medida **mediante P**, mejora con la **experiencia E**.

Ejemplos:

**T:** Reconocimiento del habla.

**P:** Distancia de edición entre transcripción real y predicha en llamados reales.

**E:** Una base de datos de conversaciones entre agentes y clientes junto a su transcripción.

**T:** Manejo autónomo en calles reales.

**P:** Distancia recorrida hasta el primer error.

**E:** Sensores en el volante, pedales y cámaras mientras maneja un humano.

**T:** Jugar al Ajedrez.

**P:** Porcentaje de juegos ganados.

**E:** Jugar contra sí mismo.

¿Qué opinan de esta P?

# Definición: “Problemas de aprendizaje bien planteados”

[Mitchell Sec. 1.1]

Un programa se dice que aprende a partir de la **experiencia E** con respecto a una **tarea T** y una medida de **performance P**, si su performance en la **tarea T**, medida **mediante P**, mejora con la **experiencia E**.

Ejemplos:

**T:** Reconocimiento del habla.

**P:** Distancia de edición entre transcripción real y predicha en llamados reales.

**E:** Una base de datos de conversaciones entre agentes y clientes junto a su transcripción.

**T:** Manejo autónomo en calles reales.

**P:** Distancia recorrida hasta el primer error.

**E:** Sensores en el volante, pedales y cámaras mientras maneja un humano.

**T:** Jugar al Ajedrez.


**P:** Porcentaje de juegos ganados online contra competidores humanos.

**E:** Jugar contra sí mismo.




# Aprendizaje Supervisado

# Aprendizaje Automático



Un concepto ¿familiar?

$$y = ax + b$$




# Un concepto familiar

Datos




Modelo(s)




Selección





# Aprendizaje Supervisado

- Dados una serie de pares  $\{\text{input}^{(i)}, \text{output}^{(i)}\}^n$
- Se construye un **modelo** que permita crear un output a partir de un input que **nunca le fueron presentados antes** sin la ayuda de decisiones definidas (implementadas) por humanos.



- Algoritmos que **"aprenden" un mapeo (función)** que relaciona **input** → **output**.
- ¿Cómo? Siguiendo **patrones** a partir de los ejemplos conocidos.



# ¿Aprendizaje Automático vs Aprendizaje Estadístico?

El **aprendizaje automático** surgió como un subcampo de la **Inteligencia Artificial**.

El **aprendizaje estadístico** surgió como un subcampo de la **Estadística**.

Hay mucho solapamiento: ambos campos se centran en problemas tanto supervisados como no supervisados:

- El **aprendizaje automático** tiene un mayor énfasis en **aplicaciones a gran escala** y **precisión de predicción**.
- El **aprendizaje estadístico** enfatiza **modelos y su interpretabilidad**, precisión e incertidumbre.

Pero la distinción se ha vuelto cada vez más difusa y hay una gran cantidad de "cruzamientos".

El **aprendizaje automático** tiene la ventaja en Marketing

**En este curso**, las técnicas que veremos pertenecen a los dos mundos por igual y abre las puertas a aplicaciones tanto científicas como ingenieriles.

# Aprendizaje Supervisado

## Clasificación vs. Regresión






# Clasificación vs. Regresión

## Clasificación

- Se busca predecir un valor perteneciente a un conjunto finito, sin orden. "Etiquetas"
- **Ejs:** ¿Spam? ¿idioma de un sitio web? ¿Tumor maligno? ¿Cambiará de compañía telefónica? ¿Dígito nombrado?

## Regresión

- Busca predecir un valor cuantitativo (enteros, reales, etc).
- Hay continuidad en las posibles salidas.
- **Ejs:** ¿Sueldo de una persona? ¿Gasto en publicidad para el año siguiente? ¿Temperatura del viernes?



### Classification

¿Soleado, nublado o lluvioso?




### Regression

¿Temperatura media mañana?



# Clasificación vs. Regresión



## Clasificación

$\text{output}^{(i)} :: \text{Bool} \mid \text{Enum}$

- Se busca predecir un valor perteneciente a un conjunto finito, sin orden. "Etiquetas"
- **Ejs:** ¿Spam? ¿idioma de un sitio web? ¿Tumor maligno? ¿Cambiará de compañía telefónica? ¿Dígito nombrado?



## Classification

¿Soleado, nublado o lluvioso?



## Regresión

$\text{output}^{(i)} :: \mathbb{N} \mid \mathbb{Z} \mid \mathbb{R} \mid \mathbb{R}^d$

- Busca predecir un valor cuantitativo (enteros, reales, etc).
- Hay continuidad en las posibles salidas.
- **Ejs:** ¿Sueldo de una persona? ¿Gasto en publicidad para el año siguiente? ¿Temperatura del viernes?



## Regression

¿Temperatura media mañana?



# Clasificación vs. Regresión

## Clasificación


$\text{output}^{(i)} :: \text{Bool} \mid \text{Enum}$

- Se busca predecir un valor perteneciente a un conjunto finito, sin orden. "Etiquetas"
- **Ejs:** ¿Spam? ¿idioma de un sitio web? ¿Tumor maligno? ¿Cambiará de compañía telefónica? ¿Dígito nombrado?

## Regresión


$\text{output}^{(i)} :: \mathbb{N} \mid \mathbb{Z} \mid \mathbb{R} \mid \mathbb{R}^d$

- Busca predecir un valor cuantitativo (enteros, reales, etc).
- Hay continuidad en las posibles salidas.
- **Ejs:** ¿Sueldo de una persona? ¿Gasto en publicidad para el año siguiente? ¿Temperatura del viernes?



Volvemos a la forma de pensar anterior.


**Importante:**  
diferencia entre Clf. y Reg. es asignar valores numéricos o etiquetas a las instancias en el espacio de atributos



# Algunas subcategorías

## Subcategorías en Clasificación

- En caso de tratarse de outputs posibles entre {True, False} decimos **“Clasificación Binaria”**
  - Ej: Este tweet, ¿es ofensivo o no lo es?.
- En caso de tratarse de outputs entre {Clase1, Clase2, Clase3, ...} decimos **“Clasificación Multiclase”**
  - Ej: ¿Qué animal (entre {Perro, Gato, Ratón}) produjo sonidos en este audio?
- En caso de tener más de una etiqueta por instancia, decimos **“Clasificación Multi-Etiqueta”**
  - Ej: ¿Qué animales (entre {Perro, Gato, Ratón}) aparecen en esta imagen?



# Adelanto de ejercicio (guía 1 – ej 2.3) (para pensar ahora)

Determinar para los siguientes problemas de aprendizaje supervisado **si se trata de problemas de clasificación o de regresión**.

Para cada caso, **indique los posibles valores que puedan tomar las etiquetas, especificando detalladamente el tipo de datos** (computacional) que le corresponde.

a) Predecir **cuánto gastará** una empresa en luz el próximo semestre.

d) Predecir si una empresa gastará **más o menos que \$50.000** por mes en luz el próximo semestre.

e) Predecir la **probabilidad** de que se gaste **más que \$50.000** por mes en luz el próximo semestre.

# Adelanto de ejercicio (guía 1 – ej 2.3) (para pensar ahora)

Determinar para los siguientes problemas de aprendizaje supervisado **si se trata de problemas de clasificación o de regresión**.

Para cada caso, **indique los posibles valores que puedan tomar las etiquetas, especificando detalladamente el tipo de datos** (computacional) que le corresponde.

a) Predecir **cuánto gastará** una empresa en luz el próximo semestre.

d) Predecir si una empresa gastará **más o menos que \$50.000** por mes en luz el próximo semestre.

e) Predecir la **probabilidad** de que se gaste **más que \$50.000** por mes en luz el próximo semestre.

**Etiquetas**  
**(en la base de datos original)**

**13k, 12.5k, 500k, etc**

**Sí, No, Sí, Sí, No, Sí**

**Sí, No, Sí, Sí, No, Sí**

**¿Cuándo un problema es de un tipo o el otro?**

Pensar en el **tipo de datos** de los ejemplos de las **etiquetas** en la base de datos: **output<sup>(i)</sup> :: ?**

# Adelanto de ejercicio (guía 1 – ej 2.3) (para pensar ahora)

Determinar para los siguientes problemas de aprendizaje supervisado **si se trata de problemas de clasificación o de regresión**.

Para cada caso, **indique los posibles valores que puedan tomar las etiquetas, especificando detalladamente el tipo de datos** (computacional) que le corresponde.

a) Predecir **cuánto gastará** una empresa en luz el próximo semestre. → **Regresión**

d) Predecir si una empresa gastará **más o menos que \$50.000** por mes en luz el próximo semestre. → **Clasificación**

e) Predecir la **probabilidad** de que se gaste **más que \$50.000** por mes en luz el próximo semestre. → **Clasificación**

**Si para (d) suponemos etiquetas como las de (a) entonces podemos encararlo con técnicas de los dos mundos (tienen sus pros y sus contras).  
Habría que analizar el caso de uso**

**Etiquetas  
(en la base de datos original)**

**13k, 12.5k, 500k, etc**

**Sí, No, Sí, Sí, No, Sí**

**Sí, No, Sí, Sí, No, Sí**

**¿Cuándo un problema es de un tipo o el otro?**

Pensar en el **tipo de datos** de los ejemplos de las **etiquetas** en la base de datos: **output<sup>(i)</sup> :: ?**



# Aprendizaje Inductivo

## [Mitchell cap. 2]

# Aprendizaje Inductivo

Guiemos la sección con un ejemplo: ¿Tiene un bote?.

En este problema, estamos interesados en **predecir** si una persona tiene, o no, un bote en base a ciertas características (**atributos**) consultadas mediante una encuesta telefónica:

- **Edad** :: Int {1, ..., 100}
- **#autos** :: Int {0, ..., 5}
- **¿Casa propia?** :: Bool
- **#hijos** :: Int {0, ..., 5}
- **estado civil** :: Enum {viudo/a, soltero/a, casado/a, divorciado/a, NA}
- **¿Tiene perros?** :: Bool

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? |
|------|--------|---------------|--------|--------------|----------------|
| 66   | 1      | sí            | 2      | viudo/a      | no             |
| 52   | 2      | sí            | 3      | casado/a     | no             |
| 22   | 0      | no            | 0      | casado/a     | sí             |
| 25   | 1      | no            | 1      | soltero/a    | no             |

Queremos pensar reglas que permitan predecir si alguien **tiene, o no, un bote**.


# Aprendizaje Inductivo: Terminología

**Función objetivo**: Estamos interesados en modelar un **proceso particular**; queremos aprender o aproximar una **función que no conocemos**, pero de la cual **tenemos ejemplos**.

**Hipótesis**: Una cierta **función que construimos y creemos** (o esperamos que sea) similar a la función objetivo que queremos modelar. La crearemos utilizando el algoritmo **L**

**Modelo**: En el campo del aprendizaje automático, los términos hipótesis y modelo a menudo se usan indistintamente.

OjO: a veces “modelo” también se utiliza para referirse al algoritmo de aprendizaje. Trataremos de evitar esta acepción.



# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Tiene un bote? |
|------|--------|---------------|--------|--------------|----------------|-----------------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | <i>sí</i>       |
| 52   | 2      | sí            | 3      | casado/a     | no             | <i>sí</i>       |
| 22   | 0      | no            | 0      | casado/a     | sí             | <i>no</i>       |
| 25   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |
| 44   | 0      | no            | 2      | divorciado/a | sí             | <i>no</i>       |
| 39   | 1      | sí            | 2      | casado/a     | no             | <i>no</i>       |
| 26   | 1      | no            | 2      | soltero/a    | sí             | <i>no</i>       |
| 40   | 3      | sí            | 1      | casado/a     | no             | <i>no</i>       |
| 53   | 2      | sí            | 2      | divorciado/a | no             | <i>sí</i>       |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | <i>no</i>       |
| 58   | 2      | sí            | 2      | casado/a     | sí             | <i>sí</i>       |
| 33   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |

**Función objetivo: ?? (desconocida)**

**Hipótesis  $H_1$**  : Si el cliente tiene casa, entonces tiene un bote. Si no, no.

# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Tiene un bote? |
|------|--------|---------------|--------|--------------|----------------|-----------------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | <i>sí</i>       |
| 52   | 2      | sí            | 3      | casado/a     | no             | <i>sí</i>       |
| 22   | 0      | no            | 0      | casado/a     | sí             | <i>no</i>       |
| 25   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |
| 44   | 0      | no            | 2      | divorciado/a | sí             | <i>no</i>       |
| 39   | 1      | sí            | 2      | casado/a     | no             | <i>no</i>       |
| 26   | 1      | no            | 2      | soltero/a    | sí             | <i>no</i>       |
| 40   | 3      | sí            | 1      | casado/a     | no             | <i>no</i>       |
| 53   | 2      | sí            | 2      | divorciado/a | no             | <i>sí</i>       |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | <i>no</i>       |
| 58   | 2      | sí            | 2      | casado/a     | sí             | <i>sí</i>       |
| 33   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |

**Función objetivo: ?? (desconocida)**

**Hipótesis  $H_1$**  : Si el cliente tiene casa, entonces tiene un bote. Si no, no.

**Accuracy** (exactitud): ? (#veces que acertamos en estos datos si utilizamos  $H_1$  dividido el total de instancias)

# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Tiene un bote? |           |
|------|--------|---------------|--------|--------------|----------------|-----------------|-----------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | sí              | Pred=sí ✓ |
| 52   | 2      | sí            | 3      | casado/a     | no             | sí              | Pred=sí ✓ |
| 22   | 0      | no            | 0      | casado/a     | sí             | no              | Pred=no ✓ |
| 25   | 1      | no            | 1      | soltero/a    | no             | no              | Pred=no ✓ |
| 44   | 0      | no            | 2      | divorciado/a | sí             | no              | Pred=no ✓ |
| 39   | 1      | sí            | 2      | casado/a     | no             | no              | Pred=sí ✗ |
| 26   | 1      | no            | 2      | soltero/a    | sí             | no              | Pred=no ✓ |
| 40   | 3      | sí            | 1      | casado/a     | no             | no              | Pred=sí ✗ |
| 53   | 2      | sí            | 2      | divorciado/a | no             | sí              | Pred=sí ✓ |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | no              | Pred=sí ✗ |
| 58   | 2      | sí            | 2      | casado/a     | sí             | sí              | Pred=sí ✓ |
| 33   | 1      | no            | 1      | soltero/a    | no             | no              | Pred=no ✓ |

**Función objetivo: ?? (desconocida)**

**Hipótesis  $H_1$  :** Si el cliente tiene casa, entonces tiene un bote. Si no, no.

**Accuracy  $H_1$  :** 75% (9/12)

# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Tiene un bote? |
|------|--------|---------------|--------|--------------|----------------|-----------------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | <i>sí</i>       |
| 52   | 2      | sí            | 3      | casado/a     | no             | <i>sí</i>       |
| 22   | 0      | no            | 0      | casado/a     | sí             | <i>no</i>       |
| 25   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |
| 44   | 0      | no            | 2      | divorciado/a | sí             | <i>no</i>       |
| 39   | 1      | sí            | 2      | casado/a     | no             | <i>no</i>       |
| 26   | 1      | no            | 2      | soltero/a    | sí             | <i>no</i>       |
| 40   | 3      | sí            | 1      | casado/a     | no             | <i>no</i>       |
| 53   | 2      | sí            | 2      | divorciado/a | no             | <i>sí</i>       |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | <i>no</i>       |
| 58   | 2      | sí            | 2      | casado/a     | sí             | <i>sí</i>       |
| 33   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |

**Hipótesis  $H_2$ :** Si el cliente tiene 52, 53, 58 o 66 años, entonces tiene un bote. Si no, no.

**Accuracy  $H_2$ :** ?

# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Tiene un bote? |           |
|------|--------|---------------|--------|--------------|----------------|-----------------|-----------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | sí              | Pred=sí ✓ |
| 52   | 2      | sí            | 3      | casado/a     | no             | sí              | Pred=sí ✓ |
| 22   | 0      | no            | 0      | casado/a     | sí             | no              | Pred=no ✓ |
| 25   | 1      | no            | 1      | soltero/a    | no             | no              | Pred=no ✓ |
| 44   | 0      | no            | 2      | divorciado/a | sí             | no              | Pred=no ✓ |
| 39   | 1      | sí            | 2      | casado/a     | no             | no              | Pred=no ✓ |
| 26   | 1      | no            | 2      | soltero/a    | sí             | no              | Pred=no ✓ |
| 40   | 3      | sí            | 1      | casado/a     | no             | no              | Pred=no ✓ |
| 53   | 2      | sí            | 2      | divorciado/a | no             | sí              | Pred=sí ✓ |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | no              | Pred=no ✓ |
| 58   | 2      | sí            | 2      | casado/a     | sí             | sí              | Pred=sí ✓ |
| 33   | 1      | no            | 1      | soltero/a    | no             | no              | Pred=no ✓ |

**Hipótesis  $H_2$ :** Si el cliente tiene 52, 53, 58 o 66 años, entonces tiene un bote. Si no, no.

**Accuracy  $H_2$ :** 100% (12/12)



# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Tiene un bote? |
|------|--------|---------------|--------|--------------|----------------|-----------------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | <i>sí</i>       |
| 52   | 2      | sí            | 3      | casado/a     | no             | <i>sí</i>       |
| 22   | 0      | no            | 0      | casado/a     | sí             | <i>no</i>       |
| 25   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |
| 44   | 0      | no            | 2      | divorciado/a | sí             | <i>no</i>       |
| 39   | 1      | sí            | 2      | casado/a     | no             | <i>no</i>       |
| 26   | 1      | no            | 2      | soltero/a    | sí             | <i>no</i>       |
| 40   | 3      | sí            | 1      | casado/a     | no             | <i>no</i>       |
| 53   | 2      | sí            | 2      | divorciado/a | no             | <i>sí</i>       |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | <i>no</i>       |
| 58   | 2      | sí            | 2      | casado/a     | sí             | <i>sí</i>       |
| 33   | 1      | no            | 1      | soltero/a    | no             | <i>no</i>       |

**Hipótesis 3:** Si el cliente tiene casa, más de 40 años y tiene al menos 1 auto, entonces tiene un bote. Si no, no.

**Accuracy  $H_3$ :** ?

# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Tiene un bote? |           |
|------|--------|---------------|--------|--------------|----------------|-----------------|-----------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | sí              | Pred=sí ✓ |
| 52   | 2      | sí            | 3      | casado/a     | no             | sí              | Pred=sí ✓ |
| 22   | 0      | no            | 0      | casado/a     | sí             | no              | Pred=no ✓ |
| 25   | 1      | no            | 1      | soltero/a    | no             | no              | Pred=no ✓ |
| 44   | 0      | no            | 2      | divorciado/a | sí             | no              | Pred=no ✓ |
| 39   | 1      | sí            | 2      | casado/a     | no             | no              | Pred=no ✓ |
| 26   | 1      | no            | 2      | soltero/a    | sí             | no              | Pred=no ✓ |
| 40   | 3      | sí            | 1      | casado/a     | no             | no              | Pred=sí ✗ |
| 53   | 2      | sí            | 2      | divorciado/a | no             | sí              | Pred=sí ✓ |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | no              | Pred=sí ✗ |
| 58   | 2      | sí            | 2      | casado/a     | sí             | sí              | Pred=sí ✓ |
| 33   | 1      | no            | 1      | soltero/a    | no             | no              | Pred=no ✓ |

**Hipótesis 3:** Si el cliente tiene casa, más de 40 años y tiene al menos 1 auto, entonces tiene un bote. Si no, no.

**Accuracy  $H_3$ :** 83% (10/12)

# Generalización





Queremos un modelo lo **suficientemente rico** para captar ideas complejas. Pero sin caer en:

## Subajuste (underfitting)

Construcción de un modelo **demasiado simple** que no capture la información disponible.

## Sobreajuste (overfitting)

Construcción de un **modelo demasiado complejo** para la cantidad de información que disponemos.



Müller, A. C., & Guido, S. (2016). Introduction to machine learning with Python: a guide for data scientists.

Además, queremos encontrar reglas que funcionen para **nuevos** ejemplos. No para los que ya conocemos su respuesta. Veremos más adelante que la forma principal de medir cómo funciona un modelo será evaluando las predicciones sobre un **conjunto "nuevo" de datos**.

# Generalización

Para intentar formalizar un poco estos conceptos, podemos utilizar las siguientes definiciones basadas en [1]

Se desea aprender una función objetivo  $\mathbf{f}^*$  **desconocida** mediante un conjunto finito de datos de entrenamiento  $\mathbf{D} = \{(\mathbf{x}^{(i)}, \mathbf{y}^{(i)})\}_{i=1}^n$ , una muestra de la distribución real (y de nuevo.. desconocida) de los datos.

Decimos que  $\mathbf{h}_{L,D}$ , un modelo construido usando el algoritmo  $\mathbf{L}$  sobre  $\mathbf{D}$  **subajusta** si:

$$(\exists h' : H) Err_{train}(h_{L,D}) \geq Err_{train}(h') \wedge Err_{true}(h_{L,D}) > Err_{true}(h')$$

Análogamente,  $\mathbf{h}_{L,D}$  **sobreajusta** si:

$$(\exists h' : H) Err_{train}(h_{L,D}) \leq Err_{train}(h') \wedge Err_{true}(h_{L,D}) > Err_{true}(h')$$

En donde

$$Err_{train}(h) = \frac{1}{|D|} \sum_{(x^{(i)}, y^{(i)}) \in D} error(h(x^{(i)}), y^{(i)})$$

$$Err_{true}(h) = \mathbb{E}_x[error(h(x), y)] = \int error(h(x), y) P(x, y) dx$$

¿De dónde sale y?

Ya veremos más adelante que  $\mathbf{y}^{(i)} \approx \mathbf{f}^*(\mathbf{x}^{(i)})$

¿Y qué es error(A, B)?

Depende del problema y del tipo de problema (reg, clasif, etc)

# Modelos Simples

En general queremos encontrar el modelo que cumpla el siguiente principio:

## Navaja de Ockham

(un principio metodológico y filosófico).

Cuando tenemos dos modelos que compiten, **producen las mismas predicciones**, debemos elegir el más simple.

Un modelo más simple es aquel que tiene menos parámetros o menor complejidad estructural.

## ¿Por qué?

En la práctica se ve que ayuda a:

- **Evitar el sobreajuste** y por lo tanto mejorar el rendimiento en datos no vistos.
- **Mejora la interpretación:** Los modelos más simples son más fáciles de interpretar y entender.
- **Reduce los costos** computacionales.

# Aprendizaje Inductivo

| Edad | #autos | ¿Casa propia? | #hijos | Estado civil | ¿Tiene perros? | ¿Compró un bote? |
|------|--------|---------------|--------|--------------|----------------|------------------|
| 66   | 1      | sí            | 2      | viudo/a      | no             | sí               |
| 52   | 2      | sí            | 3      | casado/a     | no             | sí               |
| 22   | 0      | no            | 0      | casado/a     | sí             | no               |
| 25   | 1      | no            | 1      | soltero/a    | no             | no               |
| 44   | 0      | no            | 2      | divorciado/a | sí             | no               |
| 39   | 1      | sí            | 2      | casado/a     | no             | no               |
| 26   | 1      | no            | 2      | soltero/a    | sí             | no               |
| 40   | 3      | sí            | 1      | casado/a     | no             | no               |
| 53   | 2      | sí            | 2      | divorciado/a | no             | sí               |
| 64   | 2      | sí            | 3      | divorciado/a | sí             | no               |
| 58   | 2      | sí            | 2      | casado/a     | sí             | sí               |
| 33   | 1      | no            | 1      | soltero/a    | no             | no               |

**Otro ejemplo de Hipótesis:** Si el cliente es mayor de 45 años y tiene menos de 3 chicos o no está divorciado, entonces querrá comprar un bote. Si no, no.

¿Cuál es el tamaño del **Espacio de Instancias**? (cuántas instancias posibles existen)

¿Cuál es el tamaño del **Espacio de Hipótesis**? (cuántos modelos posibles se pueden construir)

# Sustento del Aprendizaje Inductivo

## ¿Compra Bote?

Veamos cuántas posibilidades hay para cada atributo suponiendo que cada atributo puede tener:

- Edad: 100 valores posibles
- #autos: 6
- ¿casa propia?: 2
- #hijos: 5
- estado civil: 5
- ¿tiene perros?: 2

El **espacio de instancias  $X$**  contiene exactamente:  $100 * 6 * 2 * 6 * 5 * 2$  elementos.

**$|X| = 72000$**

El **espacio de hipótesis** (cuántos modelos posibles se pueden construir) contiene:

$2^{72000}$  posibles elementos (subconjuntos de  $X$ )

## Sustento del Aprendizaje Inductivo

Cualquier **hipótesis (o modelo)** que aproxime bien a la **función objetivo** sobre un conjunto **suficientemente grande de ejemplos** de entrenamiento, también **aproximará bien** a la función objetivo sobre otros **ejemplos no observados**<sup>(a)</sup>.

Si vemos el aprendizaje como un **problema de búsqueda**, necesitamos diferentes estrategias para buscar y evaluar distintos modelos en el espacio de hipótesis.

Nos interesan **algoritmos capaces de buscar eficientemente** espacios de hipótesis **muy grandes o infinitos**, para encontrar las hipótesis que **"mejor"** se ajusten a los datos<sup>(b)</sup>.

(a) [Mitchell 2.2.2 "THE INDUCTIVE LEARNING HYPOTHESIS"]

(b) [Mitchell 2.3 "CONCEPT LEARNING AS SEARCH"]

# Sesgo Inductivo

Un **conjunto finito** de datos nunca alcanza para **inferir** un único modelo. Es por ello que tenemos que agregar supuestos.

## Definición: Sesgo Inductivo

Considere un algoritmo de aprendizaje  $L$  para el dominio  $X$ . Sean

$f^*$  una función arbitraria (generalmente desconocida) definida sobre  $X$ .

$D = \{(x^{(i)}, f^*(x^{(i)}))\}_{i=1}^N$  un conjunto arbitrario de ejemplos de entrenamiento (o dataset).

$f_{L,D}(x^{(i)})$  la clasificación asignada a la instancia  $x^{(i)}$  por  $f_{L,D}$  (una función que aproxima a  $f^*$ ) construida utilizando  $L$  sobre los datos  $D$ .

Dada cualquier instancia del dominio  $X$ , llamémosla  $x$ , el **sesgo inductivo** del algoritmo  $L$  es cualquier conjunto mínimo de afirmaciones  $B$  tal que para cualquier función objetivo  $f^*$  y los ejemplos de entrenamiento de  $D$ , se puede deducir el valor  $f_{L,D}(x)$  (la predicción de la instancia  $x$  que haría el modelo resultante de entrenar a  $L$  con  $D$ ).

Mitchell lo sintetiza como:

$$(\forall x \in X)[(B \wedge D \wedge x) \vdash f_{L,D}(x)]$$

En otras palabras: **Conjunto de supuestos** que el algoritmo de aprendizaje integra al modelo que, sumado a los datos de entrenamiento, permite conocer las predicciones que hará el modelo sobre cualquier dato (voto o no visto anteriormente).

Estos supuestos pueden provenir de una variedad de fuentes, incluyendo:

- Estructura del modelo
- La función que el algoritmo esté optimizando
- Características de funcionamiento del algoritmo (cómo recorre el espacio de hipótesis hasta elegir un único modelo, la semilla random utilizada, etc)
- etc

El sesgo inductivo determina los **tipos de funciones** que el algoritmo **puede aprender** y los **tipos de errores** que un modelo construido con este **se espera que cometa**.



Algoritmo de aprendizaje:  $L$

Función objetivo

$f^* : X \rightarrow Y$

(desconocida)

Ejemplos de entrenamiento

$D = \{ \langle x^{(i)}, f^*(x^{(i)}) \rangle \}$

Algoritmo de

aprendizaje:  $L$

Hipótesis ó

Modelo:

$f_{L,D} : X \rightarrow Y$

**Espacio de hipótesis**

(muy grandes o infinito)

Espacio restringido por **Sesgo inductivo** del algoritmo  $L$

Espacio restringido por los **datos de entrenamiento  $D$**

Opciones exploradas  
(cómputo / tiempo)

$f_{L,D}$

Distancia a la función objetivo  
(error de aproximación)

★  
 $f^*$


# Resumen

- Introdujimos los distintos tipos de aprendizaje automático.
- Hablamos de la diferencia entre **aprendizaje automático** y **aprendizaje estadístico**.
- Introdujimos la diferencia entre **clasificación** y **regresión**.
- Definimos:
  - Función objetivo
  - Hipótesis / Modelo.
  - Generalización, Overfitting, Underfitting.
  - Espacio de Hipótesis e Instancias.
  - Navaja de Ockham.
  - Sustento del Aprendizaje Inductivo.
  - Aprendizaje automático como un problema de búsqueda.
  - Sesgo Inductivo.

Próximo tema: primeros modelos predictivos, Árboles de Decisión.

# TAREA

- A) Leer **Secciones 2.1 a 2.8 inclusive** del “Machine Learning” (Mitchell).
- B) Completar el **Notebooks 01** (Herramientas) y **02** (Titanic).
- C) Completar el **Cuestionario**.
- D) Armar grupos (4 personas) y subirlo al [form](#). Tienen tiempo hasta el **03/09**.
- E) Mirar este video para la próxima: <https://www.youtube.com/watch?v=YtebGVx-Fxw>



Tom Mitchell