

Cuestionario 4 - Modelos Generativos y Discriminativos

El presente es cuestionario corresponde a la Clase 4 de Aprendizaje Automático.

Para poder hacer un seguimiento de cada estudiante, por favor, usá siempre el mismo correo electrónico que tenemos registrado.

Importante: este cuestionario sólo indaga sobre como viste la clase

magaliplolek@gmail.com [Switch account](#)



Draft saved

* Indicates required question

Email *

Your email

¿Comentarios o sugerencias sobre la teórica?

1 point

Your answer



¿Comentarios o sugerencias sobre la práctica?

1 point

Your answer

¿De que carrera(s) sos? (incluí las que completaste) *

- ☒ Lic Computación
- ☐ Lic Datos
- ☐ Doctorado (compu o datos)
- ☐ Other:

Los temas que tocamos esta semana, ¿los sabías de antemano? *

	1	2	3	4	5	
Desconocidos completamente	☐	☐	☐	☒	☐	Conocidos y comprendidos de antemano



Los temas de esta semana, ¿los habías visto en alguna materia de la carrera? *

	1	2	3	4	5	
Para nada	☐	☐	☐	☒	☐	Los estudiamos con mucho detalle

El enfoque del tema, ¿qué te pareció? *

	Escasa/o	Adecuada/o	Excesiva/o
Rigurosidad de la exposición	☐	☐	☒
Ejemplos y aplicaciones	☒	☐	☐
Detalles computacionales	☐	☒	☐

¿Algún comentario que te gustaría agregar o clarificar respecto de tus respuestas anteriores?

Esa semana no pude ir a las clases. Mis respu



Sobre el contenido visto y las lecturas: V/F *

0 points

Verdadero

Falso

No sé

En la práctica, el clasificador óptimo de Bayes es imposible de calcular (por no conocer las distribuciones de los datos), en su lugar, se pueden utilizar simplificaciones a partir de hacer suposiciones (introducir sesgo inductivo).



QDA con una matriz de covarianza diagonal es equivalente a Gaussian Naive Bayes.



Los modelos generativos no permiten calcular la probabilidad a posteriori ya que no tienen suficiente información. Es decir, no permiten



calcular $P(Y=y_c | X = x^{(i)})$.

Los modelos discriminativos no permiten calcular la verosimilitud de los datos a las clases ya que no tienen suficiente información. Es decir, no permiten calcular $P(X = x^{(i)} | Y=y_c)$.



En SVM, es importante que la proyección que genera variables Slack sea eficiente.



En SVM, es importante que el producto interno entre instancias proyectadas sea eficiente.



En un problema de clasificación binario, LDA genera fronteras de decisión lineales (hiperplanos de dimensión $d-1$ que separan el espacio de atributos en 2)



Árboles de decisión puede ser visto como un modelo generativo ya que las hojas permiten obtener $P(X = x^{(i)} | Y=y_c)$



Sobre las lecturas *

0 points

Verdadero

Falso

No sé

La ecuación 4.15 indica cómo el teorema de Bayes permite descomponer a la probabilidad a posteriori en una cuenta que toma en cuenta las probabilidades a priori y las verosimilitudes por clase.



La f en la ecuación 4.15 refiere a una distribución normal multivariada.



La ecuación 4.19 muestra que la frontera de decisión en LDA, para un problema binario, siempre es el punto intermedio entre las medias de cada clase.



La Figura 4.4 muestra que la frontera de decisión teórica puede no coincidir con la estimada por un problema de estimación de las medias de cada clase.



La palabra "Linear" en LDA hace referencia a que la función discriminante (denotada con delta sombrero en el libro), es lineal con respecto a x (tiene la pinta $c_1x + c_2$). Además, la clase cuya delta sombrero sea mayor, será la clase elegida en LDA.



En la Sección 4.4.4 (luego de la ecuación 4.30) se discute si Naive Bayes Gaussiano es un caso particular de LDA y allí muestran que lo que dijimos en



clase (Naive Bayes = QDA con matriz Diagonal) no es del todo cierto.

Entendí la Figura 4.4



Entendí la Figura 4.6



En la Figura 4.9 (izquierda), que el clasificador optimo de bayes genere una frontera lineal significa que los datos fueron simulados utilizando la misma matriz de covarianza.



Sobre el Cap 9 (SVM). V/F *

6 points

Verdadero

Falso

No sé

Un hiperplano en
dimensión p es un
subespacio afín
plano de dimensión
 $p-1$.



El hiperplano de
margen máximo es
el hiperplano de
separación para el
cual el la distancia a
todas las instancias
es máxima.



Sólo 2
observaciones de
entrenamiento son
equidistantes del
hiperplano de
margen máximo.
Estos se conocen
como vectores de
soporte



C limita la suma de
los ϵ_i y, por lo tanto,
determina el número
y la gravedad de las
violaciones al



margen que
toleraremos.

Los SVM son una
extensión de Support
Vector Classifiers
que resulta de
ampliar el espacio de
atributos de una
manera específica,
utilizando kernels.



Para algunos
kernels, el espacio de
atributos implícito es
de dimensión infinita



A copy of your responses will be emailed to the address you provided.

Submit

Clear form

Never submit passwords through Google Forms.

reCAPTCHA

[Privacy](#) [Terms](#)

This content is neither created nor endorsed by Google. - [Contact form owner](#) - [Terms of Service](#) - [Privacy Policy](#)

Does this form look suspicious? [Report](#)

Google Forms

